



**MDS** Master of  
Data Science  
Universidad de Chile

# **MDS7101**

## **Estadística: Teoría y Aplicaciones**

**ESCRIBAS**

Naomí Cautivo B.  
Máximo Flores Valenzuela

# ÍNDICE

1. Semana 1: Repaso de probabilidades. ....	3
1.1. Notaciones básicas .....	3
1.2. Propiedades básicas de $\mathbb{P}$ .....	3
1.3. Variables aleatorias .....	3
1.3.1. Variables aleatorias discretas .....	3
1.3.2. Variables aleatorias continuas .....	3
1.3.3. Funciones de densidad .....	3
1.3.4. Esperanza de una variable aleatoria .....	4
1.3.5. Varianza de una variable aleatoria .....	4
1.3.6. Estandarización de una variable aleatoria .....	4
1.4. Distribuciones discretas .....	5
1.5. Distribuciones continuas .....	5
1.6. Covarianza de dos variables aleatorias .....	6
1.7. Correlación de dos variables aleatorias. ....	6
2. Semana 2: Repaso de probabilidades e inferencia estadística .....	6
2.1. Inferencia estadística .....	7
2.2. Estimadores .....	7
2.3. Intervalos de confianza .....	8
2.4. Teoría asintótica .....	10
2.4.1. Convergencia en probabilidad .....	10
2.4.2. Ejemplos de sesgo y consistencia .....	10
2.4.3. Caracterización de la consistencia .....	11
2.4.4. Ley de los Grandes Números .....	11
2.4.5. Convergencia en distribución .....	11

## 1. SEMANA 1: REPASO DE PROBABILIDADES.

- **¿Qué es una probabilidad?** Una probabilidad es una medida de incertidumbre.
- Tiene dos enfoques: frecuentista y bayesiano. Para el frecuentista, la probabilidad es algo inherente a la naturaleza, y su paradigma de cálculo es casos favorables/casos totales. Para el bayesiano, la probabilidad es un invento del ser humano, y ya no se usa la fórmula anterior.

### 1.1. NOTACIONES BÁSICAS

En el curso, usaremos  $\Omega$  para denotar el espacio muestral,  $\omega$  para los eventos, y  $\mathbb{P}$  para la medida de probabilidad, que corresponde a una función que asigna una probabilidad a cualquier evento en  $\mathcal{F}$ , donde  $\mathcal{F}$  es una colección de subconjuntos de  $\Omega$ , no necesariamente una partición.

### 1.2. PROPIEDADES BÁSICAS DE $\mathbb{P}$

- ① La probabilidad del espacio muestral debe ser siempre 1, es decir,  $\mathbb{P}(\Omega) = 1$ .
- ② La probabilidad es no negativa, es decir, para cualquier evento  $A \in \mathcal{F}$ ,  $\mathbb{P}(A) \geq 0$ .
- ③ La probabilidad de la unión de eventos disjuntos es la suma de sus probabilidades por separado, es decir,  $\mathbb{P}\left(\bigcup_i A_i\right) = \sum_i \mathbb{P}(A_i)$  cuando  $\forall i \neq j, A_i \cap A_j = \emptyset$ .

### 1.3. VARIABLES ALEATORIAS

#### Nota

Por convención, en este curso usaremos letras mayúsculas para denotar las variables aleatorias (en adelante, abreviadas como v. a.).

Son funciones que toman elementos del espacio muestral, y les asigna a cada uno un número real. Podemos definir una v. a.  $X$  como  $X : \Omega \rightarrow \mathbb{R}$ . Por ejemplo, sea  $X$  el número de caras en el lanzamiento de una moneda no cargada 3 veces, entonces  $X = \{0, 1, 2, 3\}$ , porque son las distintas cantidades de caras que pueden salir.

#### 1.3.1. VARIABLES ALEATORIAS DISCRETAS

Se dice que  $X$  es una v. a. discreta si toma valores de un conjunto finito, o infinito numerable, y además  $\forall x, \mathbb{P}(X = x) \neq 0$ .

#### 1.3.2. VARIABLES ALEATORIAS CONTINUAS

Se dice que  $X$  es una v. a. continua si  $X$  toma cualquier valor real con probabilidad cero, es decir,  $\forall x, \mathbb{P}(X = x) = 0$ .

#### 1.3.3. FUNCIONES DE DENSIDAD

Existen dos funciones de densidad que permiten ver el comportamiento de una variable aleatoria.

- PDF: *Probability Density Function* ( $f(x)$ ). Describe cómo se distribuye la probabilidad a lo largo de los posibles valores de la v. a. En específico,  $\mathbb{P}(a \leq X \leq b) = \int_a^b f(x) dx$ .
- CDF: *Cummulative Density Function* ( $F(x)$ ). Acumula la probabilidad desde  $-\infty$  hasta un valor  $x$  en el dominio. En específico,  $F(x) = \mathbb{P}(X \leq x)$ .

Estas funciones están directamente relacionadas mediante la fórmula  $F(x) = \int_{-\infty}^x f(t) dt$ , lo que puede ser observado gráficamente en la [Figura 1](#).




Figura 1: Funciones «PDF» ( $f(x)$ ) y «CDF» ( $F(x)$ ).

Si se conoce  $F$ , podemos conocer la probabilidad de un intervalo mediante la siguiente fórmula  $\mathbb{P}(a \leq X \leq b) = F(b) - F(a)$ .

### 1.3.4. ESPERANZA DE UNA VARIABLE ALEATORIA

Definimos la esperanza de una variable aleatoria para las v. a. discretas y continuas como:

- $X$  discreta:  $\mathbb{E}[X] = \sum_{\Omega} x \cdot \mathbb{P}(X = x)$ .
- $X$  continua:  $\mathbb{E}[X] = \int_{\mathbb{R}_X} x \cdot f(x) dx$ .

También se puede definir como el primer momento de distribución. Los momentos de distribución se definen como  $\mathbb{E}[X]$ ,  $\mathbb{E}[X^2]$ ,  $\mathbb{E}[X^3]$ , etc.

### 1.3.5. VARIANZA DE UNA VARIABLE ALEATORIA

Definimos la varianza de una v. a. discreta y continua como:

- $X$  discreta:  $\mathbb{V}\text{ar}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2]$ .
- $X$  continua:  $\mathbb{V}\text{ar}(X) = \int_{\mathbb{R}_X} (X - \mathbb{E}(X))^2 \cdot f(x) dx$ .

Con esto mismo podemos definir la desviación estándar de una variable aleatoria, la cual viene a ser la raíz cuadrada de su varianza. Se le conoce también como  $\sigma$  o  $\text{STD}(X)$ .

### 1.3.6. ESTANDARIZACIÓN DE UNA VARIABLE ALEATORIA

Sea  $X$  una variable aleatoria, se define la variable  $Z = (X - \mu)/\sigma$  con  $\mu = \mathbb{E}[X]$  y  $\sigma = \sqrt{\mathbb{V}\text{ar}(X)}$ . Se dice que  $Z$  es la estandarización de  $X$ , pues cumple  $\mathbb{E}[Z] = 0$  y  $\mathbb{V}\text{ar}(Z) = 1$ .

### Advertencia

En algunas librerías de programación, la «estandarización» de una v. a. se considera como su «normalización», pero estos términos no son equivalentes.

## 1.4. DISTRIBUCIONES DISCRETAS

En el curso, veremos principalmente las siguientes distribuciones discretas:

- ① Bernoulli:  $X :=$  lanzamiento de una moneda sólo una vez. Entonces  $X \sim \text{Bernoulli}(p)$ . Sus valores se definen como:

$$X = \begin{cases} 1 & \text{en el caso de éxito} \\ 0 & \text{en el caso de fracaso} \end{cases}$$

Además,  $\mathbb{P}(X = 1) = p$  (probabilidad de éxito) y  $\mathbb{P}(X = 0) = 1 - p$  (probabilidad de fracaso). El éxito puede ser, por ejemplo, «obtener cara al lanzar la moneda».

- ② Binomial: si realizamos el experimento anterior  $n$  veces, entonces  $X :=$  número de éxitos en  $n$  ensayos independientes. Luego,  $X \sim \text{Binomial}(p, n)$ . La probabilidad asociada a  $k$  éxitos es la siguiente:

$$\mathbb{P}(X = k) = \binom{n}{k} \cdot p^k \cdot (1 - p)^{n-k}$$

Además,  $\mathbb{E}(X) = np$  y  $\text{Var}(X) = np \cdot (1 - p)$ .

Si  $p$  es un vector multivariado  $(p_1, p_2, \dots, p_n)$ , se transforma en una distribución multinomial, denominada  $X \sim \text{Multinomial}(p, n)$ .

## 1.5. DISTRIBUCIONES CONTINUAS

- ① Normal:  $X \sim \mathcal{N}(\mu, \sigma^2)$ . Su función de densidad es:

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}; \quad x \in \mathbb{R}$$

- Normal estándar: si  $X \sim \mathcal{N}(\mu, \sigma^2)$  y  $Z = (X - \mu)/\sigma$ , entonces  $Z \sim \mathcal{N}(0, 1)$ .

- ② «Chi cuadrado» ( $\chi^2$ ): si  $Z \sim \mathcal{N}(0, 1)$  entonces:

$$Y = Z^2 \rightarrow Y \sim \chi^2_{[1]}$$

donde el subíndice  $[1]$  denota los grados de libertad, que es algo que se tratará en las próximas secciones.

- ③  $t$ -Student: si  $Z \sim \mathcal{N}(0, 1)$  e  $Y \sim \chi^2_{[n]}$ . Entonces definimos  $t$ -Student como:

$$t = \frac{Z}{\sqrt{Y/n}} \sim t_{[n]}$$

- ④ Fischer ( $F$ ): combinamos dos  $\chi^2$  independientes:

$$X_1 \sim \chi_{[n_1]}^2 \wedge X_2 \sim \chi_{[n_2]}^2 \text{ entonces } F = \frac{X_1/n_1}{X_2/n_2} \sim F_{n_1, n_2}$$

## 1.6. COVARIANZA DE DOS VARIABLES ALEATORIAS

Medida de cómo en promedio varían linealmente dos variables aleatorias entre sí.

$$\begin{aligned}\text{Cov}(X, Y) &= \mathbb{E}[(X - \mathbb{E}(X))(Y - \mathbb{E}(Y))] \\ &= \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y)\end{aligned}$$

Si estas variables  $X, Y$  son independientes, entonces su covarianza será cero, pues  $\mathbb{E}[XY] = \mathbb{E}[X] \cdot \mathbb{E}[Y]$  por la propiedad heredada de la esperanza.

### Advertencia

La implicancia  $\text{Cov}(X, Y) = 0 \Rightarrow X, Y$  son independientes es falsa, y es un error muy común asumir que es cierta.

## 1.7. CORRELACIÓN DE DOS VARIABLES ALEATORIAS.

Es una estandarización de la covarianza, para tener resultados interpretables en el rango  $[-1, 1]$ . Se calcula de la siguiente forma:

$$\text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \cdot \text{Var}(Y)}} = \rho(X, Y)$$

## 2. SEMANA 2: REPASO DE PROBABILIDADES E INFERENCIA ESTADÍSTICA

- Cuando decimos  $\text{Corr}(X, Y) = 0$ , quiere decir que no hay información sobre la relación lineal entre  $X$  e  $Y$ . Esto no quiere decir que  $X$  e  $Y$  sean independientes, porque pueden tener un tipo de relación no lineal, por ejemplo, cuadrática.
- Ejemplo: Sea  $X \sim U[-1, 1]$  e  $Y = X^2$ , con  $U(a, b)$  una distribución uniforme. Como los momentos de una variable  $Z$  que distribuye uniformemente en el intervalo  $(a, b)$  se calculan mediante la expresión:

$$\mathbb{E}(Z^n) = \frac{b^{n+1} - a^{n+1}}{(n+1) \cdot (b-a)}$$

y  $X$  es uniforme en el intervalo  $[-1, 1]$ , entonces su primer momento,  $\mathbb{E}(X)$ , es nulo. Además,  $\mathbb{E}(X^3) = 0$ . Esta última expresión nos sirve para deducir la contradicción, pues:

$$\begin{aligned}\text{Cov}(X, Y) &= \mathbb{E}(XY) - \mathbb{E}(X) \cdot \mathbb{E}(Y) \\ &= \mathbb{E}(XY) \\ &= \mathbb{E}(X \cdot X^2) \\ &= \mathbb{E}(X^3) = 0\end{aligned}$$

pero  $Y$  sí depende de  $X$ , entonces no pueden ser independientes.

## 2.1. INFERENCIA ESTADÍSTICA

La inferencia estadística es una rama de la estadística que se encarga de hacer **predicciones** o **caracterizaciones** sobre una población a partir de una muestra.

Normalmente, habrá una variable  $Y \sim f(X)$ , con  $f$  una función genérica llamada **modelo**, que encuentra una relación.  $Y$  se llama **variable endógena**, porque depende de  $X$ . Será la variable que estudiaremos. Por otro lado,  $X$  se llama **variable exógena**, porque en el mundo ideal no dependen de nada.

Haremos un estudio de  $X$ , con una sola variable. Por ejemplo, sea  $Y :=$  demanda por poleras, y  $X :=$  tallas (estaturas). En Chile, podríamos decir que el promedio de estatura en hombres es  $\bar{x}_H = 1.73$  m y en mujeres es  $\bar{x}_M = 1.58$  m. Diremos que el mínimo es 1 m, y el máximo es 2.5 m.

Podemos decir que las estaturas distribuyen como una variable aleatoria normal, es decir,  $X \sim \mathcal{N}(\mu, \sigma^2)$ , porque usualmente las concentraciones de estaturas toman esta forma por naturaleza.

## 2.2. ESTIMADORES

### Importante

Para hacer las estimaciones, tomamos muestras aleatorias independientes e idénticamente distribuidas (en adelante, denotado como i.i.d.). Así, la observación  $i$  no depende de la  $j$ , y todas vienen de la misma distribución. En el curso trabajaremos sólo con distribuciones i.i.d., salvo que se diga lo contrario.

En el caso anterior, no podemos conocer ni  $\mu$  ni  $\sigma$ . Como habrán casos donde esto suceda, necesitamos instrumentos que «aproximen» estos valores para poder hacer la inferencia, por ejemplo:

$$\bar{X} = \frac{1}{N} \cdot \sum_{i=1}^N X_i$$

- **¿Por qué nos gusta el promedio?** El promedio cumple con propiedades que hacen que sea un buen estimador. Una de ellas se enlista a continuación:

- **Insensgadez.** Sea  $T(X)$  estimador del parámetro  $\theta$ .  $T(X)$  es **insesgado** si  $\mathbb{E}[T(X)] = \theta$ . Esto significa que su valor esperado está completamente centrado en el parámetro que estoy buscando. Esta propiedad la cumple el promedio:

$$\begin{aligned} \mathbb{E}(\bar{X}) &= \mathbb{E}\left(\frac{1}{N} \cdot \sum_{i=1}^N X_i\right) \\ &= \frac{1}{N} \cdot \sum_{i=1}^N \mathbb{E}(X_i) \quad (\text{linealidad}) \\ &= \frac{1}{N} \cdot N \cdot \mu = \mu \quad (X_i \text{ i.i.d.}) \end{aligned}$$

Definimos  $\mathbb{V}\text{ar}(T(X))$  como la medida de dispersión del estimador, es decir, qué tan lejos me encuentro del «centro». Para el promedio:

$$\begin{aligned}\mathbb{V}\text{ar}(\bar{X}) &= \mathbb{V}\text{ar}\left(\frac{1}{N} \cdot \sum_{i=1}^N X_i\right) \\ &= \frac{1}{N^2} \cdot \mathbb{V}\text{ar}\left(\sum_{i=1}^N X_i\right) \\ &= \frac{1}{N^2} \cdot \sum_{i=1}^N \mathbb{V}\text{ar}(X_i) \quad (X_i \text{ i.i.d.}) \\ &= \frac{1}{N^2} \cdot N \cdot \sigma^2 = \frac{\sigma^2}{N}\end{aligned}$$

A propósito, queremos que la varianza sea lo más cercana a cero posible, porque esto hace que el estimador esté concentrado en el valor central. Lo malo del resultado obtenido con el promedio, es que si  $N$  es muy grande, no podré estimar  $\sigma$  (que sigue siendo desconocido), porque  $N$  tiene influencias en el resultado al estar dividiendo.

De esto, nace la necesidad de buscar un estimador insesgado de  $\sigma^2$ . La expresión que toma es la que sigue:

$$S^2 = \frac{1}{N-1} \cdot \sum_{i=1}^N (X_i - \bar{X})^2; \quad \mathbb{E}(S^2) = \sigma^2$$

De esta forma, ya tenemos una estimación de  $\sigma^2$ , por lo tanto, podemos decir que  $\mathbb{V}\text{ar}(\bar{X}) = S^2/N$  con un error  $\text{STD}(\bar{X}) = \sqrt{S^2/N}$ .

### 2.3. INTERVALOS DE CONFIANZA

Se anotan como  $\text{IC}(\bar{X})$ ,  $\text{CI}(\bar{X})$  o  $\text{C}(\bar{X})$ , y corresponden a un rango de valores que con cierta probabilidad contienen al parámetro de interés  $\theta$ . Lo importante es notar que el parámetro de interés está fijo, lo que varía es justamente el intervalo de confianza.

$$\text{C}(\bar{X}) = \bar{X} \pm Z_\alpha \cdot \text{STD}(\bar{X})$$

El valor  $Z_\alpha$  es el que escojo para que con « $\alpha$ » nivel de confianza  $\mu \in \text{C}(X)$ .

$$\begin{aligned}\mathbb{P}(\mu \in \text{C}(\bar{X})) &= \mathbb{P}(\bar{X} - Z_\alpha \cdot \text{STD}(\bar{X}) \leq \mu \leq \bar{X} + Z_\alpha \cdot \text{STD}(\bar{X})) \\ &= \mathbb{P}\left(-Z_\alpha \leq \underbrace{\frac{\bar{X} - \mu}{\text{STD}(\bar{X})}}_{\text{estadístico } t} \leq Z_\alpha\right)\end{aligned}$$

Para fijar la probabilidad de que el parámetro de interés esté en el intervalo de confianza, necesitamos saber cómo distribuye el estadístico  $t$ . Vamos a ver algunos ejemplos.



- ①  $X \sim \mathcal{N}(\mu, \sigma^2)$ , y supondremos que conocemos  $\sigma^2$ . Entonces  $\bar{X} \sim \mathcal{N}(\mu, \sigma^2/N)$  por los cálculos que hicimos anteriormente. Luego,

$$Z \sim \frac{\bar{X} - \mu}{\text{STD}(\bar{X})} \sim \mathcal{N}(0, 1) \quad (\text{es una normal estandarizada})$$

Para una normal  $\mathcal{N}(0, 1)$ , el valor de  $Z_\alpha$  es aproximadamente 1.96 para una estimación del 95% de confianza para  $\mu$  (o sea,  $\alpha = 1 - 0.95 = 0.05$ ). Este valor de  $Z_\alpha$  varía en función de la probabilidad asociada a la estimación.

- ②  $X \sim \mathcal{N}(\mu, \sigma^2)$ , pero no conocemos  $\sigma^2$ . Nuevamente,  $\bar{X} \sim \mathcal{N}(\mu, \sigma^2/N)$ . Luego, queremos conocer cómo distribuye  $Z = (\bar{X} - \mu) / \sqrt{S^2/N}$ . Para esto, necesitamos escribir  $Z$  de manera conveniente. Se escribirá de la siguiente forma:

$$Z = \frac{\bar{X} - \mu}{\sqrt{\sigma^2/N}} \bigg/ \sqrt{\left( (N-1) \cdot \frac{S^2}{\sigma^2} \right) / (N-1)}$$

Ya sabemos que  $(\bar{X} - \mu) / \sqrt{\sigma^2/N} \sim \mathcal{N}(0, 1)$ . Nos falta estimar el resto. Desarrollando:

$$(N-1) \cdot \frac{S^2}{\sigma^2} = \frac{1}{N-1} \sum_{i=1}^N [(X_i - \bar{X})^2] \cdot \frac{N-1}{\sigma^2} = \sum_{i=1}^N \left( \frac{X_i - \bar{X}}{\sigma} \right)^2$$

y además,  $(X_i - \bar{X})/\sigma \sim \mathcal{N}(0, 1)$ , entonces  $(N-1) \cdot S^2/\sigma^2 \sim \chi^2_{[N-1]}$ , pues es una suma de normales al cuadrado. Finalmente, y por definición de la variable aleatoria  $t$ -Student,  $Z$  distribuye  $t_{[N-1]}$ .

### 📢 Importante

La suma de variables  $\chi^2$  independientes sigue siendo  $\chi^2$ . Los grados de libertad de la variable resultante son la suma de los grados de libertad de las variables originales.

- ③  $X$  no distribuye  $\mathcal{N}(\mu, \sigma^2)$ . Para este caso, es útil emplear una herramienta visual para descartar que su distribución se comporte de forma parecida a una normal. Una manera es usando un  $Q-Q \text{ Plot}$  que compara cuantil a cuantil una distribución empírica con una teórica. En este caso, la distribución empírica es  $X$ , y la teórica sería una normal.

En la [Figura 2](#) que se muestra a continuación, mientras más cerca esté la línea de puntos azul de la recta, más parecidas son las distribuciones empírica y teórica. Estos roles los toman  $X$  y  $\mathcal{N}(\mu, \sigma^2)$  respectivamente en el caso que estamos estudiando.




Figura 2: Visualización simplificada de un Q-Q Plot.

Si se logra confirmar visualmente que no distribuye normal, debemos buscar otras estrategias para entender la distribución del estadístico  $t$ . En este punto, introduciremos la teoría asintótica, que se definirá en la siguiente sección ([Sección 2.4](#)).

## 2.4. TEORÍA ASINTÓTICA

### 2.4.1. CONVERGENCIA EN PROBABILIDAD

Una secuencia de variables aleatorias  $X_n$  converge en probabilidad a la variable aleatoria  $X$  si para todo  $\varepsilon > 0$ , su límite cumple lo siguiente:

$$\lim_{n \rightarrow \infty} \mathbb{P}(|X_n - X| < \varepsilon) = 1$$

Esto se anotará como  $X_n \rightarrow_{\mathbb{P}} X$  ó  $\text{plim}_{n \rightarrow \infty} X_n = X$ .

#### Nota

En la mayoría de los *datasets* actuales se tiene que « $n \rightarrow \infty$ », porque en la estadística clásica, un  $n = 30$  ya era considerado muy grande. Esto es porque una  $t$ -Student con 30 grados de libertad se empieza a parecer a una normal estándar en distribución.

Basándose en esto se puede definir una nueva propiedad para los estimadores, que extiende la propiedad de insesgadez que se vio en la [Sección 2.2](#):

- **Consistencia:** Un estimador  $T(X_n)$  del parámetro  $\theta$  es **consistente** si converge en probabilidad al parámetro de interés, es decir:

$$\lim_{n \rightarrow \infty} \mathbb{P}(|T(X_n) - \theta| < \varepsilon) = 1$$

### 2.4.2. EJEMPLOS DE SESGO Y CONSISTENCIA

Un estimador puede ser insesgado y no consistente, o tener otro tipo de variaciones. A continuación, se enlistan ejemplos que dan cuenta de estas variaciones:

- ① Estimador insesgado e inconsistente:

$$T'(X) = X_1 \wedge \mathbb{E}(T'(X)) = \mathbb{E}(X_1) = \mu$$

Este estimador de  $\mu$  es insesgado, porque su esperanza es igual al parámetro estimado, sin embargo, al aumentar la muestra ( $n \rightarrow \infty$ ), el valor de  $T'(X)$  no cambia, sigue siendo aleatorio e igual a  $X_1$ . Al ser un valor aleatorio, esto no se acerca una distancia arbitraria  $\varepsilon > 0$  a  $\mu$  en el límite.

② Estimador sesgado e inconsistente:

$$T''(X) = c \in \mathbb{R}, c \neq \theta$$

En este caso, al ser una constante, el valor esperado es la misma constante (distinta de  $\theta$ ), por lo tanto, cumple ser sesgado. Por otro lado, es inconsistente, ya que la sucesión siempre está concentrada en  $c$ , lo que hace imposible que esté centrado en  $\theta$ , que es lo que se busca con el límite.

③ Estimador sesgado y consistente:

$$S'^2 = \frac{1}{N} \sum_{i=1}^N (X_i - \bar{X})^2; \mathbb{E}(S'^2) = \sigma^2 - \frac{\sigma^2}{N} \neq \sigma^2$$

Este estimador tiene sesgo, porque su valor esperado no es igual al parámetro estimado  $\sigma^2$ . Sin embargo, es consistente, porque converge en probabilidad al parámetro de interés. Esto último se confirma porque el sesgo es  $-\sigma^2/N$ , que tiende a 0 cuando  $N \rightarrow \infty$ .

### 2.4.3. CARACTERIZACIÓN DE LA CONSISTENCIA

Si  $T(X_n)$  es estimador insesgado de  $\theta$ , es decir,  $E(T(X_n)) = \theta$ , y además  $\text{Var}(T(X_n)) \rightarrow 0$  cuando  $n \rightarrow \infty$ , entonces  $T(X_n)$  es un estimador consistente de  $\theta$ . Matemáticamente:

$$T(X_n) \text{ insesgado} \wedge \text{Var}(T(X_n)) \rightarrow 0 \implies T(X_n) \text{ consistente}$$

Por ejemplo, el promedio es un estimador consistente de  $\mu$ , porque es un estimador insesgado ( $E(\bar{X}) = \mu$ ), y además  $\text{Var}(\bar{X}) = \sigma^2/N \rightarrow 0$  cuando  $N \rightarrow \infty$ .

### 2.4.4. LEY DE LOS GRANDES NÚMEROS

Sea  $\{X_i\}_{i \in \mathbb{N}}$  una muestra i.i.d. con  $E(X_i) = \mu < \infty$  y  $\text{Var}(X_i) = \sigma^2 < \infty$  para todo  $i \in \mathbb{N}$ . La Ley de los Grandes Números (también llamada LGN) establece que:

$$\bar{X}_n = \frac{1}{n} \cdot \sum_{i=1}^n X_i$$

es un estimador consistente de  $\mu$ , es decir,  $\bar{X}_n \xrightarrow{\mathbb{P}} \mu$ .

### 2.4.5. CONVERGENCIA EN DISTRIBUCIÓN

Sea  $X_n$  es una secuencia de variables aleatorias con  $X_n \sim f_n(\cdot)$ , y además  $X \sim f(\cdot)$ . Si para cada  $x$  donde  $f(x)$  es continua se cumple que  $f_n(x) \xrightarrow{n \rightarrow \infty} f(x)$  entonces decimos que  $X_n$  converge en distribución a  $X$ , anotado  $X_n \xrightarrow{d} X$ .